

Análise descritiva e estatística de uma base de dados

Maria Sobreira

2025-04-10

PROJETO DA DISCIPLINA

Análise de Dados

Aluno: MARIA CLARA SILVA SOBREIRA Nessa disciplina, foram somados ao conhecimento de análise exploratória de dados, aspectos importantes do dia a dia de um cientista de dados: distribuição dos dados, imputação de dados, visualização de dados, construção de dashboards e relatórios.

Base de dados A escolha do dataset de vinhos foi motivada pela possibilidade de analisar as variáveis que representam características físico-químicas de vinhos, como teor alcoólico, acidez e compostos fenólicos. Essa base é comumente utilizada para a classificação de vinhos em 3 tipos, mas neste trabalho o foco está na análise exploratória dos dados, tal como é o proposto para a disciplina.

Dessa maneira, espera-se encontrar insights a partir das variáveis Álcool, Acidez Málica, Intensidade da cor e dos compostos fenólicos (Total_Phenols e Flavanoids). Também espera-se analisar as estatísticas descritivas de variáveis numéricas, como:

- média do teor alcoólico, indicando vinhos mais fortificados ou suaves;
- dispersão da acidez málica, verificando as diferenças significativas entre os vinhos; e,
- correlação entre as variáveis Phenols e Flavanoids, pois vinhos com mais fenólicos tendem a ser mais adstringentes.

```
## [1] "Alcohol"           "Malic_Acid"         "Ash"
## [4] "Ash_Alcanity"      "Magnesium"          "Total_Phenols"
## [7] "Flavanoids"        "Nonflavanoid_Phenols" "Proanthocyanins"
## [10] "Color_Intensity"   "Hue"                 "OD280"
## [13] "Proline"
```

- Apresentando as primeiras linhas do banco de dados de Vinhos.

```
##   Alcohol Malic_Acid Total_Phenols Flavanoids Color_Intensity
## 1   14.23     1.71         2.80       3.06         5.64
## 2   13.20     1.78         2.65       2.76         4.38
## 3   13.16     2.36         2.80       3.24         5.68
## 4   14.37     1.95         3.85       3.49         7.80
## 5   13.24     2.59         2.80       2.69         4.32
## 6   14.20     1.76         3.27       3.39         6.75
```

```
##      Alcohol      Malic_Acid      Total_Phenols      Flavanoids
## Min.       :11.03   Min.       :0.740   Min.       :0.980   Min.       :0.340
```

```
## 1st Qu.:12.36 1st Qu.:1.603 1st Qu.:1.742 1st Qu.:1.205
## Median :13.05 Median :1.865 Median :2.355 Median :2.135
## Mean :13.00 Mean :2.336 Mean :2.295 Mean :2.029
## 3rd Qu.:13.68 3rd Qu.:3.083 3rd Qu.:2.800 3rd Qu.:2.875
## Max. :14.83 Max. :5.800 Max. :3.880 Max. :5.080
## Color_Intensity
## Min. : 1.280
## 1st Qu.: 3.220
## Median : 4.690
## Mean : 5.058
## 3rd Qu.: 6.200
## Max. :13.000
```

Identificando os tipos de cada variável na base

- A função `diagnose` foi utilizada para identificar tipos de variável, unicidade e proporção de *missing values*.

Como a base original não possui dados faltantes, precisei gerar valores vazios (aleatoriamente) para a variável “Malic_Acid”.

```
## Registered S3 methods overwritten by 'dlookr':
##   method          from
##   plot.transform  scales
##   print.transform scales

##
## Anexando pacote: 'dlookr'


## O seguinte objeto é mascarado por 'package:base':
##
##   transform

## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr      1.1.4    v readr      2.1.5
## v forcats    1.0.0    v stringr    1.5.1
## v ggplot2    3.5.1    v tibble     3.2.1
## v lubridate  1.9.3    v tidyr      1.3.1
## v purrr      1.0.2
## -- Conflicts ----- tidyverse_conflicts() --
## x tidyr::extract() masks dlookr::extract()
## x dplyr::filter()  masks stats::filter()
## x dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

A tibble: 5 x 6

```
variables types missing_count missing_percent unique_count unique_rate 1 Alcohol numeric 0 0 126 0.708
2 Malic_Acid numeric 17 9.55 127 0.713 3 Total_Phenols numeric 0 0 97 0.545 4 Flavanoids numeric 0
0 132 0.742 5 Color_Intensity numeric 0 0 132 0.742 # A tibble: 1 x 6 variables types missing_count
missing_percent unique_count unique_rate 1 Malic_Acid numeric 17 9.55 127 0.713
```

```
##
## Anexando pacote: 'gridExtra'
##
## O seguinte objeto é mascarado por 'package:dplyr':
##
##     combine
```



Análise de frequências da variável Ácido Málico (com dados faltantes)

- Utilizado a função `freq()` do pacote `summarytools` para calcular as frequências relativas

As variáveis `Alcool` e `Total_Phenols` apresentam as frequências semelhantes a uma distribuição normal.

```
##
## Anexando pacote: 'summarytools'

## O seguinte objeto é mascarado por 'package:tibble':
##
##     view
```

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
0.74	1	0.62	0.62	0.56	0.56

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
0.89	1	0.62	1.24	0.56	1.12
0.9	1	0.62	1.86	0.56	1.69
0.92	1	0.62	2.48	0.56	2.25
0.94	2	1.24	3.73	1.12	3.37
0.98	1	0.62	4.35	0.56	3.93
0.99	1	0.62	4.97	0.56	4.49
1.01	1	0.62	5.59	0.56	5.06
1.09	1	0.62	6.21	0.56	5.62
1.1	1	0.62	6.83	0.56	6.18
1.13	2	1.24	8.07	1.12	7.30
1.17	1	0.62	8.70	0.56	7.87
1.19	1	0.62	9.32	0.56	8.43
1.21	1	0.62	9.94	0.56	8.99
1.24	1	0.62	10.56	0.56	9.55
1.25	1	0.62	11.18	0.56	10.11
1.29	2	1.24	12.42	1.12	11.24
1.34	1	0.62	13.04	0.56	11.80
1.35	3	1.86	14.91	1.69	13.48
1.36	1	0.62	15.53	0.56	14.04
1.39	1	0.62	16.15	0.56	14.61
1.41	1	0.62	16.77	0.56	15.17
1.43	1	0.62	17.39	0.56	15.73
1.45	1	0.62	18.01	0.56	16.29
1.47	1	0.62	18.63	0.56	16.85
1.48	1	0.62	19.25	0.56	17.42
1.5	2	1.24	20.50	1.12	18.54
1.51	1	0.62	21.12	0.56	19.10
1.52	1	0.62	21.74	0.56	19.66
1.53	3	1.86	23.60	1.69	21.35
1.57	1	0.62	24.22	0.56	21.91
1.59	1	0.62	24.84	0.56	22.47
1.6	1	0.62	25.47	0.56	23.03
1.61	2	1.24	26.71	1.12	24.16
1.63	2	1.24	27.95	1.12	25.28
1.64	2	1.24	29.19	1.12	26.40
1.65	2	1.24	30.43	1.12	27.53
1.66	2	1.24	31.68	1.12	28.65
1.67	4	2.48	34.16	2.25	30.90
1.68	2	1.24	35.40	1.12	32.02
1.7	1	0.62	36.02	0.56	32.58
1.71	2	1.24	37.27	1.12	33.71
1.72	2	1.24	38.51	1.12	34.83
1.73	5	3.11	41.61	2.81	37.64
1.75	2	1.24	42.86	1.12	38.76
1.76	1	0.62	43.48	0.56	39.33
1.77	2	1.24	44.72	1.12	40.45
1.78	1	0.62	45.34	0.56	41.01
1.8	1	0.62	45.96	0.56	41.57
1.81	4	2.48	48.45	2.25	43.82
1.83	1	0.62	49.07	0.56	44.38
1.86	1	0.62	49.69	0.56	44.94
1.87	2	1.24	50.93	1.12	46.07

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
1.88	1	0.62	51.55	0.56	46.63
1.9	2	1.24	52.80	1.12	47.75
1.92	1	0.62	53.42	0.56	48.31
1.95	1	0.62	54.04	0.56	48.88
1.97	1	0.62	54.66	0.56	49.44
1.99	1	0.62	55.28	0.56	50.00
2.02	1	0.62	55.90	0.56	50.56
2.05	1	0.62	56.52	0.56	51.12
2.06	1	0.62	57.14	0.56	51.69
2.08	1	0.62	57.76	0.56	52.25
2.12	1	0.62	58.39	0.56	52.81
2.13	1	0.62	59.01	0.56	53.37
2.15	1	0.62	59.63	0.56	53.93
2.16	2	1.24	60.87	1.12	55.06
2.31	1	0.62	61.49	0.56	55.62
2.36	1	0.62	62.11	0.56	56.18
2.39	1	0.62	62.73	0.56	56.74
2.4	1	0.62	63.35	0.56	57.30
2.43	1	0.62	63.98	0.56	57.87
2.45	1	0.62	64.60	0.56	58.43
2.46	1	0.62	65.22	0.56	58.99
2.51	1	0.62	65.84	0.56	59.55
2.55	1	0.62	66.46	0.56	60.11
2.56	1	0.62	67.08	0.56	60.67
2.58	1	0.62	67.70	0.56	61.24
2.59	1	0.62	68.32	0.56	61.80
2.67	1	0.62	68.94	0.56	62.36
2.68	1	0.62	69.57	0.56	62.92
2.76	1	0.62	70.19	0.56	63.48
2.81	1	0.62	70.81	0.56	64.04
2.83	1	0.62	71.43	0.56	64.61
2.89	1	0.62	72.05	0.56	65.17
2.96	1	0.62	72.67	0.56	65.73
2.99	1	0.62	73.29	0.56	66.29
3.03	2	1.24	74.53	1.12	67.42
3.1	1	0.62	75.16	0.56	67.98
3.12	1	0.62	75.78	0.56	68.54
3.17	2	1.24	77.02	1.12	69.66
3.24	1	0.62	77.64	0.56	70.22
3.26	1	0.62	78.26	0.56	70.79
3.27	1	0.62	78.88	0.56	71.35
3.3	1	0.62	79.50	0.56	71.91
3.43	2	1.24	80.75	1.12	73.03
3.45	1	0.62	81.37	0.56	73.60
3.55	1	0.62	81.99	0.56	74.16
3.57	1	0.62	82.61	0.56	74.72
3.59	2	1.24	83.85	1.12	75.84
3.7	1	0.62	84.47	0.56	76.40
3.74	1	0.62	85.09	0.56	76.97
3.8	1	0.62	85.71	0.56	77.53
3.83	1	0.62	86.34	0.56	78.09
3.84	1	0.62	86.96	0.56	78.65

	Freq	% Valid	% Valid Cum.	% Total	% Total Cum.
3.86	1	0.62	87.58	0.56	79.21
3.87	1	0.62	88.20	0.56	79.78
3.88	1	0.62	88.82	0.56	80.34
3.9	1	0.62	89.44	0.56	80.90
3.91	1	0.62	90.06	0.56	81.46
3.98	1	0.62	90.68	0.56	82.02
3.99	1	0.62	91.30	0.56	82.58
4.04	1	0.62	91.93	0.56	83.15
4.1	1	0.62	92.55	0.56	83.71
4.12	1	0.62	93.17	0.56	84.27
4.28	1	0.62	93.79	0.56	84.83
4.3	1	0.62	94.41	0.56	85.39
4.31	1	0.62	95.03	0.56	85.96
4.36	1	0.62	95.65	0.56	86.52
4.43	1	0.62	96.27	0.56	87.08
4.61	1	0.62	96.89	0.56	87.64
4.95	1	0.62	97.52	0.56	88.20
5.04	1	0.62	98.14	0.56	88.76
5.19	1	0.62	98.76	0.56	89.33
5.51	1	0.62	99.38	0.56	89.89
5.8	1	0.62	100.00	0.56	90.45
<NA>	17			9.55	100.00
Total	178	100.00	100.00	100.00	100.00

Pela frequência relativa, nota-se que 9,5% (17 das 178 observações) dos dados de **ácido málico** estão sem valor na base de Vinhos e 30% dos dados apresentam valores em torno de 1,67.

Análise descritiva e de histogramas de uma variável contínua

- Variável Alcool é analisada descritivamente.
- A centralidade dos dados, a dispersão, a assimetria, bem como as estatísticas de ordem são calculadas, a fim de ter uma leitura acerca da distribuição dessa variável.

A média do teor alcoólico é de 13%, com desvio padrão de 0,81 e amplitude de 3.08, indicando que os dados são pouco dispersos e com a presença de vinhos mais fortificados.

Com relação aos ácidos málicos, a média é de 2.33, com valor mínimo de 0.74 e máximo de 5.80. Além disso, as distâncias entre quartis, indicam uma grande dispersão dos dados. Assim, temos diferenças significativas entre os vinhos (características e propriedades de composição).

Descriptive Statistics

wine\$Alcohol N: 178

	Alcohol
Mean	13.00
Std.Dev	0.81
Min	11.03
Q1	12.36


	Alcohol
Median	13.05
Q3	13.68
Max	14.83
MAD	1.01
IQR	1.32
CV	0.06
Skewness	-0.05
SE.Skewness	0.18
Kurtosis	-0.89
N.Valid	178.00
N	178.00
Pct.Valid	100.00

Descriptive Statistics


wine\$Malic_Acid N: 178

	Malic_Acid
Mean	2.33
Std.Dev	1.09
Min	0.74
Q1	1.60
Median	1.87
Q3	3.10
Max	5.80
MAD	0.79
IQR	1.50
CV	0.47
Skewness	0.95
SE.Skewness	0.19
Kurtosis	0.09
N.Valid	161.00
N	178.00
Pct.Valid	90.45


Distribuição de Álcool na base




Distribuição de Ácido malico na base




Distribuição de Total_Phenols na base



Distribuição de Flavanoids na base



Distribuição de Intensidade da Cor dos vinhos



Pela distribuição das frequências, nota-se um agrupamento dos dados de intensidade da cor, no qual 70% dos dados possuem valores de até 5,7.

Análise visual da variável Intensidade de cor

- Calculando o histograma da variável **Intensidade de cor** com o número de *bins* calculado a partir da função de Sturges.

Função de Sturge para cálculo do número de bins:

```
sr <- function(x) {  
  n <- length(x)  
  return((3.49*sd(x))/n^(1/3))  
}
```


```
sr (wine$Color_Intensity)
```

```
## [1] 1.43831
```

A base de vinhos possui 178 registros. Por esse motivo, foi aplicada a função de Sturges por ser o método que melhor se adequa em bases com poucas observações e ideal para dados com distribuição semelhante a normal. O valor de bins obtido foi igual a 1,4.

Análise visual da variável Intensidade de cor - leitura


1. Assimetria com cauda à direita.
2. Centralidade dos dados calculada pela média sofre pouca contaminação em relação aos valores mais distantes do centro da distribuição.
3. A maior parte dos dados está concentrada em torno de 5.0, indicando que cores intensas são mais frequentes na base.
4. Embora seja uma base de poucas observações, os dados não apresentaram dispersão elevada e com a maioria dos dados está concentrada próxima ao centro da distribuição.



Criando a Matriz de espalhamento

```
## Registered S3 method overwritten by 'GGally':  
##   method from  
##   +.gg      ggplot2  
  
## 'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.  
## 'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.  
## 'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.  
## 'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.  
## 'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.
```

Matriz de Espalhamento - Análise de Vinhos



Assim como era esperado para Total_Phenol e Flavanoids, as variáveis possuem forte correlação positiva, com coeficiente de correlação igual a 0,87 e um forte agrupamento dos dados em torno da reta, havendo indício de que à medida que aumenta o Total_Phenol do vinho, também pode-se aumentar os Flavanoids.

Nota-se pelo com coeficiente de correlação igual a 0.99, que ALcool e Ácido málico possuem alta correlação positiva. Contudo, o espalhamento entre as variáveis em torno da reta, indica uma grande dispersão dos dados.

Alcool e Intensidade da cor possuem uma correlação positiva fraca, de valor 0,5.

Distribuição dos dados

A distribuição normal, também chamada de distribuição gaussiana, é uma das formas de distribuição de probabilidade que descreve como os dados tendem a se agrupar em torno de uma média, seguindo um padrão simétrico e bem definido. Nesse tipo de distribuição, o lado direito é uma imagem espelhada do lado esquerdo e a medida que os valores se afastam da média tendem a ser menos frequentes.

Gráfico Quartil-Quartil (Q-Q)

Gráfico Q-Q para Alcool




Gráfico Q-Q para Malic_Acid




Gráfico Q-Q para Total_Phenols




Gráfico Q-Q para Flavanoids





Gráfico Q-Q para Intensidade de Cor



Shapiro-test

o teste de Shapiro-Wilk é uma técnica estatística usada para avaliar a normalidade dos dados.

O shapiro-test para Alcohol e Total_Phenols, retornaram p-value de 0.02 e 0.004, respectivamente. Como os valores são inferiores a 0.05, as variáveis não possuem distribuição normal.

Shapiro-Wilk normality test

data: wine\$Alcohol W = 0.9818, p-value = 0.02005

Shapiro-Wilk normality test

data: wine\$Total_Phenols W = 0.97668, p-value = 0.004395

Compleitude de dados

A completude de dados refere-se à ausência de valores (missing values) em um conjunto de dados. Na análise exploratória de dados, a presença de dados faltantes pode impactar nas respostas e nos insights obtidos no estudo, refletindo na tomada de decisões e nas aplicações das informações. Em uma base com falta de completude, os resultados podem conter viés (quando os dados omitidos não forem aleatórios), reduzir a significância estatística (pela exclusão do tamanho da amostra), apresentar divergências nas métricas e trazer prejuízos na construção de modelos estatísticos.

Imputação de Dados e MICE (Multiple Imputation by Chained Equations)


A imputação de dados é o processo de preencher valores faltantes em um conjunto de dados baseado em padrões observados.

```
##  
## Anexando pacote: 'mice'
```

```
## O seguinte objeto é mascarado por 'package:stats':  
##  
## filter
```

```
## Os seguintes objetos são mascarados por 'package:base':  
##  
## cbind, rbind
```


```
iter imp variable 1 1 Malic_Acid 1 2 Malic_Acid 1 3 Malic_Acid 1 4 Malic_Acid 1 5 Malic_Acid 2 1  
Malic_Acid 2 2 Malic_Acid 2 3 Malic_Acid 2 4 Malic_Acid 2 5 Malic_Acid 3 1 Malic_Acid 3 2 Malic_Acid  
3 3 Malic_Acid 3 4 Malic_Acid 3 5 Malic_Acid 4 1 Malic_Acid 4 2 Malic_Acid 4 3 Malic_Acid 4 4  
Malic_Acid 4 5 Malic_Acid 5 1 Malic_Acid 5 2 Malic_Acid 5 3 Malic_Acid 5 4 Malic_Acid 5 5 Malic_Acid  
6 1 Malic_Acid 6 2 Malic_Acid 6 3 Malic_Acid 6 4 Malic_Acid 6 5 Malic_Acid 7 1 Malic_Acid 7 2  
Malic_Acid 7 3 Malic_Acid 7 4 Malic_Acid 7 5 Malic_Acid 8 1 Malic_Acid 8 2 Malic_Acid 8 3 Malic_Acid  
8 4 Malic_Acid 8 5 Malic_Acid 9 1 Malic_Acid 9 2 Malic_Acid 9 3 Malic_Acid 9 4 Malic_Acid 9 5  
Malic_Acid 10 1 Malic_Acid 10 2 Malic_Acid 10 3 Malic_Acid 10 4 Malic_Acid 10 5 Malic_Acid
```



Min. 1st Qu. Median Mean 3rd Qu. Max. 0.740 1.593 1.845 2.328 3.083 5.800

Verificando a base de álcool com os dados faltantes de ácido málico

Nota-se que mesmo com dados faltantes em ácido málico, a perda de informação está bem distribuída para todos os valores de Alcool, não existindo a presença de concentração de dados faltantes nos subconjuntos (agrupados pela frequência) da variável analisada.



Dashboard Shiny

Links

Acesse a fonte da base de dados do trabalho - Wine Quality: <https://archive.ics.uci.edu/dataset/186/wine+quality>

Acesse o trabalho publicado no GitHub: [GitHub](#)

FIM




Figure 1: Dashboard